

Sentiment-Analysis und Pragmatik

Gamze Uysal

Universität Stuttgart, Pfaffenwaldring 7, 70563 Stuttgart-Vaihingen, Deutschland

B.Sc. Softwaretechnik

E-Mail: st142819@stud.uni-stuttgart.de

Zusammenfassung. Durch die Interaktivität der sozialen Netzwerke werden riesige Datenmengen generiert. Diese Daten sind überall: im Web, auf dem Mobiltelefon, im Posteingang, auf dem Dateisystem. Sie enthalten wertvolle Informationen für Unternehmen. Denn Tweets, Facebook-Statusmeldungen, Kundenbewertungen usw. geben Einblick in die Welt der Zielgruppe. Zudem beeinflussen sie die öffentliche Wahrnehmung von Produkten, Dienstleistungen und Personen. Ob Busverspätungen, Wahlchancen oder Produktreklamationen – der Kunde spricht öffentlich darüber. Wie zufrieden der Kunde ist, lässt sich messen. Die Methode heißt Sentiment-Analyse: Was das genau ist, wie sie funktioniert und wie die Firmen davon profitieren, wird in dieser Ausarbeitung vorgestellt.

Diese Ausarbeitung befasst sich mit den verschiedenen Methoden, die zur Klassifizierung eines gegebenen Textes in natürlicher Sprache, gemäß den darin geäußerten Meinungen und Gefühlen, verwendet werden. Ferner werden in dieser Seminararbeit zwei grundsätzliche Formen der Sentiment-Analyse unterschieden. Zum einen die lexikonbasierte und zum anderen die maschinelle Analyse. Darunter gibt es noch weitere verschiedene Methoden und Algorithmen zur Klassifizierung, die grob erläutert werden. Während die Sentiment-Analyse für Englisch und für Textsorten wie Produktbewertungen schon viel Aufmerksamkeit erhalten hat, ist die Sentiment-Analyse für Sprachen wie Deutsch und für andere Textsorten noch etwas unbekannter und auch weniger weit fortgeschritten. Das Ziel dieser Ausarbeitung ist folglich, im Rahmen des Studienprojekts „*KIKuKo: KI-gestützte Plattform für die Kundenkommunikation*“ am IAT der Universität Stuttgart / Fraunhofer IAO, die in der zu erstellenden Webapplikation hochgeladenen Beschwerdetexte nach ihrem Sentiment zu klassifizieren.

Schlüsselwörter: Sentiment-Analyse, Pragmatik, Sentiment, Ironie, Sarkasmus, lexikonbasiert, maschinelles Lernen, Klassifikation, Naive-Bayes, Maximum-Entropy, Support-Vector-Machine, überwachtes/unüberwachtes Lernen.

1 Grundlagen

1.1 Sentiment-Analyse

Die Sentiment-Analyse (engl.: Sentiment-Analysis) ist eine Technologie zur Verarbeitung der natürlichen Sprache, die analysiert, welche Meinungen, Gefühle oder Einstellungen in einem Text geäußert werden. Es wird demnach analysiert, ob der Text im

Allgemeinen als positiv (Wörter wie z.B. „gut“) oder negativ (z.B. „schlecht“) wahrgenommen wird oder eher neutral ist. Dabei können Verfahren aus den Bereichen Künstliche Intelligenz, Natural Language Processing (NLP), Data Mining, Text Mining, Web Mining, Machine Learning, Statistik und Information Retrieval zum Einsatz kommen. In der Forschungsliteratur werden synonym für Sentiment-Analyse oft auch die Begriffe „Sentiment Detection“, „Opinion Mining“, oder „Opinion Extraction“ verwendet.[1]

Die Sentiment-Analyse kann auf unterschiedlichen linguistischen Ebenen durchgeführt werden. Dabei unterscheidet sich nicht nur die sprachliche Einheit, sondern auch die damit verbundenen Aufgaben und Einsatzmöglichkeiten. Die in der Literatur am häufigsten eingesetzten Ebenen der Sentiment-Analyse unterscheidet B. Liu [2]: die Dokumentenebene, die Satzebene und die Aspektebene. Dabei soll jeweils die in einem Dokument, einem Satz, oder einer Phrase geäußerte Meinung erkannt und als positive oder negativ eingeordnet werden. Bevor die Polarität eines Satzes erkannt werden kann, muss zudem noch bestimmt werden, ob ein Satz objektiv (Fakten vermittelnd) oder subjektiv (Meinungen vermittelnd) ist. [2]

Dokumentenebene.

Die Sentiment-Analyse auf Dokumentenebene ist die gröbste Form der Sentimenterkennung. Hier wird die Stimmung eines ganzen Dokuments bestimmt, also es wird angenommen, dass ein Dokument genau eine Meinung über ein Thema enthält. Dabei wird die Analyse auf einzelne Sätze, die sich auf mehrere Entitäten in einem ganzen Dokument beziehen, nicht beachtet.[3]

Satzebene.

Bei der Sentiment-Analyse auf Satzebene können zu einem Thema auch mehrere Meinungen bestehen. Dabei wird angenommen, dass ein Satz jeweils eine Meinung zum besprochenen Thema enthält. Diese Ebene ist eng verbunden mit der Klassifikation von objektiven bzw. subjektiven Sätzen, wobei diese Sätze ebenfalls positive, negative oder neutrale Stimmung beinhalten können. Die vorliegende Arbeit beschäftigt sich ausschließlich mit dem für die Sentiment-Analyse relevanten Bereich der subjektiven Aussagen, da objektive Aussagen i.), Fakten über ein Objekt, einer Person oder ein Vorgehen beinhalten. Wohingegen subjektive Aussagen ii.) meist auf Emotionen basierende Äußerungen und Meinungen sind.[3]

- i. Das Haus ist weiß.
- ii. Das Haus ist schön.

Aspektebene.

Allerdings kann es auch sein, dass in einem Satz mehrere Meinungen zu unterschiedlichen Aspekten vorkommen, z.B. wenn verschiedene Attribute eines Produkts bewertet werden. In diesem Fall ist Sentiment-Analyse auf Phrasenebene am besten geeignet. Dabei wird versucht sog. „opinion targets“, d.h. Wörter die ausgedrückte Stimmung abzielt, herauszufinden.[3]

Die in der Literatur präsentierten Ansätze zur Sentiment-Analyse lassen sich aber noch weiter klassifizieren. Dabei besteht ein grundsätzlicher Unterschied zwischen lexikon-basiertem Ansatz und dem Ansatz des maschinellen Lernens. Dies wird im Abschnitt 3 dieser Arbeit weiter erläutert.

1.2 Pragmatik

Die Pragmatik analysiert den Inhalt konkreter sprachlicher Äußerungen, also Vorgänge, welche in einer „konkreten Situation“ und im Zusammenhang mit einem „Kontext“ von einer Person ausgeführt werden oder von einer Person wahrgenommen wurden (zwischenmenschliche Kommunikation).

Unter die Pragmatik fallen unter anderem: Ironische Äußerungen, wie z. B. „Das hast Du ja wieder mal ganz toll hingekriegt!“. Nach der Wortbedeutung eigentlich ein Lob, ist es je nach Tonfall, eine negative Aussage, wenn z. B. gerade ein Teller auf den Boden gefallen ist. [4]

Deshalb sind der kommunikative Sinn und Absicht vom großen Interesse für die Pragmatik. Der kommunikative Sinn sagt uns, welche Absicht die Person mit seiner Äußerung verfolgt, und welche Bedeutung zugrunde liegt. Es kann nicht allein von der Bedeutung des Satzes abgeleitet werden, sondern muss durch die Äußerung und den Kontext erschlossen werden. Wird der Satz ironisch geäußert, weil man beispielsweise eine Sache völlig vermässelt hat, hat sie eine gegenteilige Bedeutung. Das heißt also die Pragmatik befasst sich mit Bedeutungsaspekten der Äußerungen. [5]

Erkennung von Ironie.

Eine von mehreren möglichen Ausdrucksformen der persönlichen Sichtweisen ist die Ironie. Das Erkennen von Ironie ist eines der größten Schwachpunkte der Systeme. Smilies und andere Zeichenketten tragen des Weiteren zur Sinngestaltung bei und müssen vom Analyser erfasst und interpretiert werden. Erstreckt sich die Kritik über einen langen zusammenhängenden Text, müssen des Weiteren Sinnzusammenhänge erkannt und zugeordnet werden. Da Ironie als eine von vielen möglichen Formen der Bewertung gilt und somit auch Stimmungen ausdrückt, spielt sie bei der Sentiment Analyse eine wesentliche Rolle. [6] Ihre Grundfunktion besteht laut empirischer Untersuchungen darin, negative Bewertungen zu äußern. Ironie wird als rhetorisches Stilmittel eingesetzt, bei dem eine „Ersetzung des eigentlichen durch den entgegengesetzten Ausdruck.“ [7] stattfindet, doch soll der Leser dabei die wahre Meinung aus dem Zusammenhang erkennen. Die Sentiment Analyse von Kundenrezensionen wird durch die Verwendung von Ironie erschwert. Die korrekte Erkennung von Ironie kann daher zu einem präziseren Ergebnis führen. Die bisher gemachten Forschungen zeigen, dass eine maschinelle Erkennung von Ironie einer Abstraktion von linguistischem und sozialem Wissen bedarf. Die Erfassung von Ironie mit statistischen Methoden ist so gut wie nicht möglich, daher bietet die Erfassung mit lokalen Grammatiken in diesem Bereich einige Vorteile. Ironie kann beispielsweise nicht allein auf Grund eines einzelnen Wortes erfasst werden, sondern nur unter der Berücksichtigung semantischer Kriterien, welche statistische Methoden in dieser Form nicht liefern können. [7]

Erkennung von Sarkasmus.

Sarkasmus ist eine der am schwierigsten zu erkennenden Eigenschaften menschlicher Sprache, nicht nur für Maschinen, sondern ebenso für Menschen. Es ist eine Art von Gefühl, in dem Menschen ihre negativen Gefühle durch positive oder intensivierte positive Worte im Text ausdrücken. Welche eindeutig das Gegenteil von dem bedeuten, was sie sagen, um jemandes Gefühle zu verletzen oder jemanden etwas auf humorvolle Weise zu kritisieren. Während des Sprechens verwenden Menschen oft starken tonalen Stress und bestimmte gestische Anhaltspunkte wie das Rollen der Augen, Handbewegungen usw., um sarkastisch zu klingen. Zur richtigen Interpretation ist also ein Abgleich der Aussage mit dem Objekt beziehungsweise Sachverhalt, den er beschreibt, notwendig. In den Textdaten fehlen diese tonalen, optischen und gestischen Hinweise (Mimik), was die Sarkasmuserkennung sehr schwierig macht. Aufgrund dieser Herausforderungen zeigen Forscher Interesse an Sarkasmus-Erkennung von Social-Media-Text, vor allem in Tweets. Das schnelle Wachstum von Tweets und deren Analyse stellen große Herausforderungen dar.[8]

2 Anwendungsbereiche

Mit steigender Bekanntheit von Unternehmen, Events, Personen etc. steigt auch automatisch die Menge an Interessenten. Das hat zur Folge das die Frequenz und die Menge an Datensätzen sich parallel dazu erhöht. Eine manuelle Sentiment-Analyse kommt daher nicht mehr in Frage. Der Fokus liegt hierbei auf der automatisierten Sentiment-Analyse, welche effizient und nach vorgegebenen Regeln zuverlässig arbeitet. Diese Faktoren sind wichtig für die Anwendungsgebiete der automatisierten Sentiment-Analyse, da der Einsatz auch in Bereichen wie z.B. dem Sicherheitssektor immer eine größere Rolle spielt.[9]

Die Analyse der öffentlichen Meinung auf sozialen Netzwerken über zukünftige Ereignisse, wie Demonstrationen oder Paraden und kann wertvolle Informationen liefern. Dadurch ist es möglich das Ausmaß einer potenziellen Störung, Unordnung oder eines Angriffes während dieser Ereignisse einzuschätzen. Ein weiterer Punkt ist die Verwendung der Analyse im Strafverfolgungssektor. Durch eine Sentiment-Analyse über Mitgliedern fraglicher Organisationen ist es eventuell möglich die „Stimmung“ bzw. das Gefährdungspotenzial der Organisation abzuschätzen. [10]

Ein weiterer Anwendungsbereich für das Verfahren ist die Politik, welche meist im Internet sehr heftig diskutiert wird. Die Analyse von politischen Meinungen, Texten und Kommentaren, kann Politikern die Chance geben in „Echtzeit“ die Meinung über die eigene Partei oder Person abzuschätzen. Ein Beispiel dafür ist die Obama-Verwaltung welche im Jahre 2012 die Sentiment-Analyse dafür nutzte Ihren „Stand“ im Volk einzuschätzen. [11]

Auch das Marketing verwendet die automatisierte Sentiment-Analyse, um Meinungen einzuholen über Produkte und über ihre bestimmten Features. Dafür werden Kundenmeinungen, Rezensionen, bestimmte Foren etc. analysiert. Wichtig ist hierbei ein sehr genaues Verfahren. Es ist Beispielsweise möglich das ein Produkt zwar sehr Positive Resonanzen zeigt, aber dennoch ein bestimmtes feature bemängelt wird. Ebenfalls

könnte man identifizieren, welche Altersgruppen, welche Resonanzen über das Produkt geben. Sollte es ein „physisches“ sein könnte man die bemängelten Punkte im nächsten kommenden Produkt verbessern. Einfacher wäre es z.B. bei Software. Hier kann man relativ zeitnah mit einem Update darauf reagieren. [12]

Es gibt natürlich noch viele weitere Anwendungsgebiete. Diese würden aber den Rahmen dieses Seminares sprengen, deshalb wird hier nichts weiteres mehr dazu erwähnt.

3 Sentiment-Klassifikation

In der Sentiment-Analyse ist die Sentiment-Klassifikation einer der bisher am besten erforschten Bereiche. Ein Text, der positive, negative oder neutrale Aussagen enthält, wird mit Hilfe von Klassifikationsalgorithmen entsprechend kategorisiert. Grundsätzlich arbeiten automatische Methoden der Sentiment-Analyse entweder lexikonbasiert oder auf Basis von maschinellen Lernverfahren. Eine Übersicht über die verschiedenen Sentiment-Klassifikationstechniken geben Medhat et al. in der Arbeit „Sentiment analysis algorithms and applications: A survey“ [13]. Sie illustriert den Zusammenhang zwischen den erwähnten Sentiment-Analyseansätzen und nennt jeweils die dazugehörigen häufig verwendete Algorithmen. In diesem Kapitel werden die beiden in Abbildung 1 dargestellten grundlegenden Ansätze mit ihren verschiedenen Techniken sowie computerlinguistische Verfahren vorgestellt. [13]

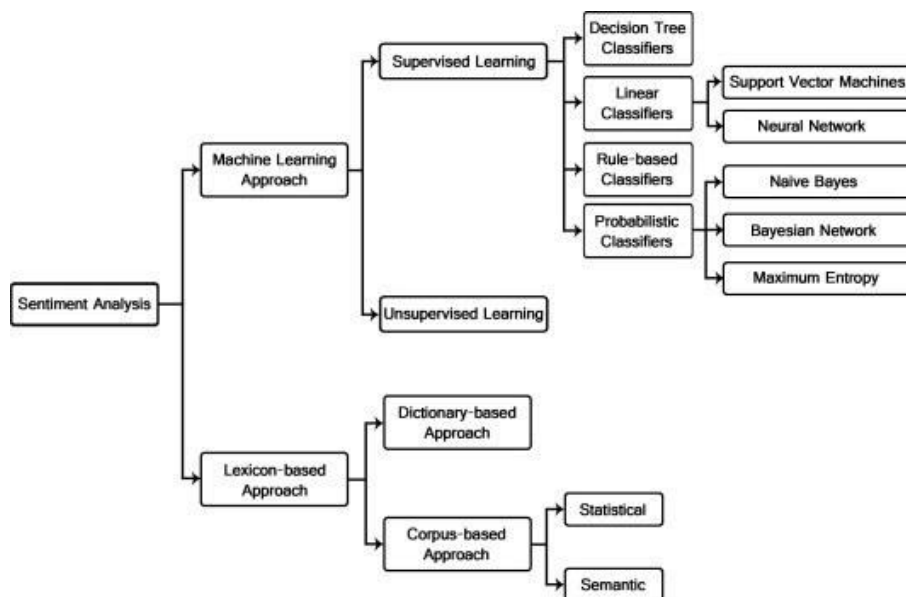


Abb. 1. Sentiment-Klassifikationstechniken im Überblick [Medhat et al., 2014]

3.1 Lexikonbasiert

Bei dem lexikonbasierten Ansatz werden als Basis ein Wörterbuch oder ein Korpus verwendet, um die Polarität eines Dokuments/Satzes oder einer Phrase zu bestimmen. Die Methode ermittelt die Gesamtpolarität bezogen auf das Vorkommen von bestimmten Wörtern, die in einem Wörterbuch definiert sind und eine gewisse Polarität beinhalten. Wenn beispielsweise ein Wort mit einem Wort im Wörterbuch übereinstimmt, das im Wörterbuch als positiv markiert ist, wird die Gesamtpolarität des Texts erhöht. Wenn der Gesamtpolaritätswert eines Textes positiv ist, wird dieser Text als positiv klassifiziert, andernfalls wird er als negativ klassifiziert. Generell liegt der Fokus bei den lexikonbasierten Ansätzen auf Adjektiven als Indikatoren für die semantische Orientierung eines Textes. [3] Obwohl dieser Ansatz sehr grundlegend erscheint, wurde berichtet, dass Varianten dieses lexikalischen Ansatzes eine sehr hohe Genauigkeit aufweisen. [14] Der größte Vorteil dieser Technik besteht darin, dass keine Trainingsdaten benötigt werden, wie beim Ansatz des maschinellen Lernens, während der schwächste Punkt darin besteht, dass eine große Anzahl von Wörtern und Ausdrücken nicht in Sentiment-Lexika enthalten ist. Deshalb ist es bei lexikonbasierten Techniken nicht so leicht, die Bedeutung hinter der Kombination der Bedingungen zu verstehen. Dies hängt damit zusammen, dass sie nur die Existenz der Wörter erkennt, die einer positiven oder negativen Stimmung zugeordnet sind, aber nicht, wie sie zusammenwirken. Der Gebrauch von komplizierten Negationen oder vor allem Ironie oder Sarkasmus, ist eine Herausforderung für lexikonbasierte Techniken, um die Stimmung korrekt vorauszusagen. [7]

Die Sentiment-Klassifikation mit lexikonbasierten Ansätzen wird in die drei Ansätze manuell, wörterbuchbasiert und korpusbasiert aufgeteilt, die wie folgt vorgestellt werden.

Manueller Ansatz.

Bei diesem Ansatz nehmen Menschen die Sichtung der entsprechenden Daten vor. Sie bewerten die in den Dokumenten oder Texten in sozialen Medien geäußerten Meinungen bezüglich positiver, negativer oder neutraler Tonalität. Manuell eine Sentiment Wortliste zu erstellen, ist ein aufwändiger Prozess, der unterstützend zu anderen Ansätzen, angewendet werden kann. Beschränkt man sich dabei auf eine spezielle Domäne, kann man mit einer manuellen Erweiterung der Sentiment Wortliste gute Ergebnisse erzielen.

Wörterbuchbasierter Ansatz.

Bei dem wörterbuchbasierten Ansatz wird vorerst manuell ein kleines Set an Sentiment Wörtern mit bekannter Polarität gesammelt. Mit Hilfe von bestehenden Lexika wird dieses Set durch gefundene Synonyme und Antonyme angereichert. Mit dem neu gewonnenen Set an Wörtern wird dieser Prozess wiederholt, bis keine neuen Wörter mehr gefunden werden. Um Wörterbücher nicht vollständig manuell erstellen zu müssen, werden bestehende lexikalische Ressourcen wie z.B. WordNet®, die von der

Universität Princeton bereitgestellt wird, verwendet. [15] Im deutschsprachigen Raum bietet sich GermaNet [16] oder SentiWS [17] als lexikalische Datenbank an.

Korpusbasierter Ansatz.

Beim korpusbasierten Ansatz haben wir es nicht mit isolierten Wörtern und Sätzen zu tun, sondern mit zusammenhängenden Sinneinheiten. Es wird eine Liste mit Stimmungswörtern erstellt und durch andere Stimmungswörter im verwendeten Korpus erweitert, um so kontextspezifische Informationen zu erhalten. Dadurch wird die emotionale Affinität von Wörtern automatisch bestimmt. [18]

Bei diesem Ansatz handelt es sich um einen Iterationsprozess, bei dem die weiteren Ergebnisse auf der Startmenge gründen. Aus diesem Grund können Fehler auftreten. Damit die Sentiment-Klassifikation weitestgehend fehlerfrei ist, sollte ein manueller Verifikationsprozess stattfinden, um einen Korpus zu untersuchen. Dies könnte unter Verwendung statistischer oder semantischer Methoden erfolgen, wie man auch aus der Abbildung 1 entnehmen kann. Mit dem statistischen Ansatz können ähnliche Meinungswörter fündig gemacht werden, die über die Häufigkeit des Miteinanderauftretens gefunden werden. Mit dem semantischen Ansatz werden die Ähnlichkeiten der Wörter über ihre semantische Nähe bestimmt, beispielsweise mit Hilfe der semantischen Relationen von WordNet®. [13]

3.2 Maschinelles Lernen

Maschinelles Lernen ist ein Teilgebiet der künstlichen Intelligenz. Mithilfe des maschinellen Lernens können, auf Basis vorhandener Datenbestände und Algorithmen, Muster und Gesetzmäßigkeiten erkannt und Lösungen entwickelt werden. Es wird quasi künstliches Wissen aus Erfahrungen generiert. Die aus den Daten gewonnenen Erkenntnisse lassen sich verallgemeinern und für neue Problemlösungen oder für die Analyse von bisher unbekannten Daten verwenden. Je größer die Datenmenge, auf die die Algorithmen zugreifen können, desto mehr lernen sie. [19]

Somit können in der Sentiment-Analyse auch unbekannte Texte analysiert werden, um die Tonalität herauszufinden. Es wird auf die Verwendung von Sentiment-Lexika verzichtet. Entscheidend sind also nur die Trainingsdaten. Problematisch bei dem maschinellen Lernverfahren ist, dass man zunächst genügend große Trainings- und Testmengen manuell aufbereiten muss, damit das Modell eine größtmögliche Abdeckung innerhalb des Anwendungsbereiches (Domäne) hat. Ein solches Modell ist zudem, im Gegensatz zu den lexikonbasierten Ansätzen, nicht ohne weiteres auf neue Domänen anwendbar: Wenn eine Software beispielsweise anhand von Kundenrezensionen über Autos trainiert wurde, dann wird sie bei der Auswertung von Filmkritiken versagen. [20] Das maschinelle Lernen unterscheidet grundsätzlich zwischen überwachten Lernverfahren (supervised learning) und unüberwachten Lernverfahren (unsupervised learning). Überwachtes Lernen bedeutet, dass ein System mittels bereitgestellten Daten und Klassen darauf trainiert wird, neue Instanzen in eine der vorgegebenen Klassen einzuordnen. Für die Sentiment-Analyse wären zum Beispiel „positiv“ und „negativ“ naheliegende Klassen. Die Testdaten werden also anhand eines vorgegebenen Bereichs

klassifiziert und die Ausgabe wird dadurch vorgegeben. Im Gegensatz dazu soll ein System beim unüberwachten Lernen durch die Analyse der Lexik und Syntax einer Instanz eine Vorhersage über deren Sentiment machen. Dabei bestimmt ein Grenzwert, ab wann eine Instanz als „positiv“ bzw. „negativ“ gilt. Es existieren also Lernmuster in der Eingabe, aber es liegen keine spezifischen Ausgabewerte vor. [3]

Überwachtes Lernen.

Das wichtigste Element beim überwachten Lernen ist der Klassifikator, der verschiedenen Sentiments in vorgegebene Kategorien einordnet. Mit einer Basis von bekannten Fällen, deren betrachtete Sentiments bereits klassifiziert sind, wird das Lernen praktiziert. Das ausgewählte, aber noch nicht angepasste Modell muss nun so konfiguriert werden, dass die bekannten Fälle möglichst gut reproduziert werden können. Kurzgefasst ist das Ziel überwachter Lernmethoden, fehlende Informationen auf Grund von Beobachtungen vorherzusagen. [21]

Viele der in Abbildung 1 dargestellten Verfahren wurden in der vergangenen Forschung auf dem Gebiet der Sentiment Analyse bereits effektiv angewendet. Diese Arbeit konzentriert sich auf drei Verfahren, die zu den am häufigsten verwendeten Klassifikationstechniken des maschinellen Lernens gehören. Im Folgenden werden die Klassifizierer Naïve Bayes, Maximum-Entropy und Support-Vector-Machines vorgestellt und notwendige Grundlagen erläutert.

Naïve-Bayes-Klassifikation.

Der Naïve-Bayes-Klassifikator zählt zu den probabilistischen und häufig verwendeten Klassifikatoren im Bereich des überwachten Lernverfahrens. Im Kontext der Satzebene berechnet der Klassifikator die Wahrscheinlichkeit für die Zugehörigkeit eines bestimmten Satzes zu einer Polaritätsklasse (a-posteriori Wahrscheinlichkeit). Es wird vorausgesetzt, dass mindestens eine Sammlung von Texten mit vordefinierten Meinungen und Faktenlabels auf Dokumentebene verfügbar ist. Der Klassifikator nimmt dabei an, dass alle Wörter oder Features eines Satzes statistisch voneinander unabhängig sind und die gleiche Wichtigkeit haben. Da diese Annahme in der Praxis zumeist falsch ist, wird der Klassifikator als „naiv“ bezeichnet. [22]

Da der Naïve-Bayes-Klassifikator auf dem Bayes-Theorem aufbaut, wird zunächst dieses Konzept vorgestellt. Am Ende dieses Abschnittes wird eine Möglichkeit vorgestellt, um sogenannte Nullwahrscheinlichkeiten zu verhindern.

Bei der Naïve-Bayes-Klassifikation wird einem Dokument d eine bestimmte Klasse c („positiv“ oder „negativ“) zugeordnet. Dabei wird mit Wahrscheinlichkeitswerten gearbeitet, indem versucht wird, die Wahrscheinlichkeit für die Zugehörigkeit eines Dokuments zu einer Klasse zu bestimmen. Zur Bestimmung der a-posteriori Wahrscheinlichkeit verwendet der Naïve-Bayes-Klassifikator das Bayes-Theorem:

$$P(c|d) = \frac{P(c) P(d|c)}{P(d)}$$

$P(d|c)$ ist die bedingte Wahrscheinlichkeit dafür, dass der Feature d in einer der festgelegten Klassen c auftritt. Durch die Vereinfachung der Berechnung, in der angenommen wird, dass die Features des Textes unabhängig voneinander sind und dass die Position des Features im Satz/Text ignoriert wird, wird der Klassifikator „naiv“. [7]

Nutzt man den Klassifikator streng nach obiger Definition kommt man – gerade bei dem Anwendungsszenario von Texten – zu dem Problem, dass bestimmte Worte überhaupt nicht in den Trainingsdaten vorkamen oder in einer Klasse schon, in der anderen gar nicht. Dadurch kann es dazu kommen, dass Wahrscheinlichkeiten den Wert $P(c|d) = 0$ annehmen. Um dieses Problem zu beheben wird eine Glättung (engl. smoothing) Π hinzugefügt, um Nullwahrscheinlichkeiten zu vermeiden. Um dies auf ein Textklassifikationsproblem anzuwenden, werden noch ein Set von n Eigenschaften (f_1, \dots, f_n) hinzugefügt, die in einem Dokument vorkommen können. $n_i(d)$ ist die Anzahl von Eigenschaften f_i die in einem Dokument auftreten. Die Trainingsdaten bestehen aus relativen Häufigkeiten von $P(c)$ und $P(f_i|c)$. [23]

$$P_{NB}(c|d) = \frac{P(c) (\prod_{i=1}^m P(f_i|c)^{n_i(d)})}{P(d)}$$

Maximum-Entropy-Klassifikation.

Das Konzept der Maximum-Entropy-Methode beruht auf der Entropie (engl. Entropy). Die Entropie ist ein Maß für den Informationsgehalt eines Wortes. Zum Beispiel hat das Wort „super“ eine höhere Gewichtung als das Wort „gut“. Die Maximum Entropy-Klassifikation ist eine alternative Technik zur Naive-Bayes-Klassifikation. Ähnlich wie der NB-Klassifikator berechnet also der ME-Klassifikator die bedingte Wahrscheinlichkeit zwischen einer Klasse und einem Feature-Vektor, wobei jedoch keine Vermutungen über Beziehungen von Wörtern getroffen werden. Hier werden die Features (Eigenschaften der Wörter) gewichtet. Demnach ist ME-Klassifikation dem Naive-Bayes vorzuziehen. Man geht davon aus, dass Attribute mit einem hohen Gewichtungsfaktor die Trainingsmenge am besten klassifizieren. [13]

Folgende Exponentialfunktion dient zur Berechnung der Maximum-Entropy:

$$P_{ME}(c|d) := \frac{1}{Z(d)} \exp\left(\sum \lambda_{i,c} F_{i,c}(d, c)\right)$$

Wobei $Z(d)$ eine Normalisierungsfunktion ist. $F_{i,c}$ ist eine Feature-/Klassenfunktion für die Feature f_i und die Klasse c , die dann wie folgt definiert ist:

$$F_{i,c}(d, c') := \begin{cases} 1, & n_i(d) > 0 \text{ and } c' = c, \\ 0, & \text{otherwise} \end{cases}$$

Die $\lambda_{i,c}$'s in der obigen Gleichung sind die Parameter für die Gewichtung der einzelnen Eigenschaften. [24]

Klassifikation mit Support-Vector-Maschinen.

Die Klassifikation durch Support-Vektor-Maschinen gehört zu den am häufigsten eingesetzten Verfahren im Bereich der Sentiment-Analyse. Die Grundlegende Funktionsweise einer SVM ist es, in einem Vektorraum eine (optimal) separierende Hyperebene zu positionieren, die die Trainingsdaten in zwei unterschiedliche Klassen teilt. Es entstehen dabei sogenannte Stützvektoren. Stützvektoren sind die Vektoren, die der Hyperebene am nächsten liegen. Dabei soll der Abstand zur Hyperebene maximiert werden. Es entsteht dadurch ein breiter leerer Raum zwischen der Hyperebene und den Stützvektoren. Er dient später dazu, Objekte, die nicht genau den Trainingsdaten entsprechen, einordnen zu können. [25]

Die optimal separierende Hyperebene kann wie folgt aufgestellt werden. Angenommen wird die Trainingsmenge x_n und Klassen y_n für ein binäres Klassifikationsproblem, sodass nachfolgende Bedingungen erfüllt sind:

$$(x_1, y_1), \dots, (x_n, y_n), x \in \mathbb{R}^n, y \in \{+1, -1\}.$$

Die Trainingsdaten können durch eine Hyperebene mit nachfolgender Geradengleichung separiert werden:

$$(w \cdot x) + b = 0.$$

Dabei beschreibt w einen Normalenvektor der Hyperebene, b einen Bias, sodass die Hyperebene nicht durch den Koordinatenursprung laufen muss, sowie das Skalarprodukt $(w \cdot x)$ aus Normalenvektor und Trainingsdatum. Eine Hyperebene teilt somit einen n -dimensionalen Raum in 2 Hälften (im Fall eines Sentiments, „positiv“ und „negativ“). Das Ziel dieses Vorgehens ist es, einen Klassifikator auf Basis von Trainingsdaten zu entwickeln, der Testdaten mittels Features automatisch richtig klassifiziert. Eine Testbeobachtung wird dabei einer Klasse oberhalb oder unterhalb der Hyperebene zugeordnet: [22]

$$\begin{aligned} (w \cdot x) + b &\geq 1 \text{ wenn } y_i = 1 \\ (w \cdot x) + b &\leq -1 \text{ wenn } y_i = -1. \end{aligned}$$

Formal haben wir dann zwei verschiedene Klassen in $c_j(1, -1)$. Die 1 steht in unserem Fall für ein „positives“ Sentiment und die -1 für „negatives“ Sentiment. Die korrekten Klassen der Dokumente d_j sind dann:

$$\vec{w} = \left(\sum_j a_j, c_j, \vec{d}_j \right), \quad a_j > 0,$$

wobei d_j und $a_j > 0$ Stützvektoren sind, die sie zum Vektor w beisteuern. Die Klassifizierung von Testinstanzen besteht einfach darin, zu bestimmen, auf welche Seite der Hyperebene \vec{w} sie fallen. [24]

Der Vorteil dieser Klassifikation besteht darin, dass das Modell nach der Trennung die Zielklassen (Sentiment) für neue Fälle leicht erraten kann. Eine gute Trennung wird natürlich durch die Hyperebene erreicht, die den größten Abstand zum nächstgelegenen

Trainingsdatenpunkt einer Klasse hat. Je größer der Spielraum, desto geringer ist der Verallgemeinerungsfehler des Klassifizierers.

Über die Hyperebene hinaus unterscheidet man noch zwischen den linear separierbaren und den nicht-linear separierbaren Daten. Auf der linken Seite in Abbildung 2 (A) sehen wir, wie eine Hyperebene zwischen den positiven und den negativen Stützvektoren gezogen wurde. Sie trennt die Gesamtheit aller Dokumente in zwei Klassen. Je nachdem, auf welcher Seite der Hyperebene ein neuer Stützvektor auftaucht, gehört das Dokument entweder zur Klasse „positiv“ oder „negativ“. Der lineare Klassifikator trifft seine Klassifizierungsentscheidung also auf der Grundlage einer linearen Kombination von Eigenschaften. [26]

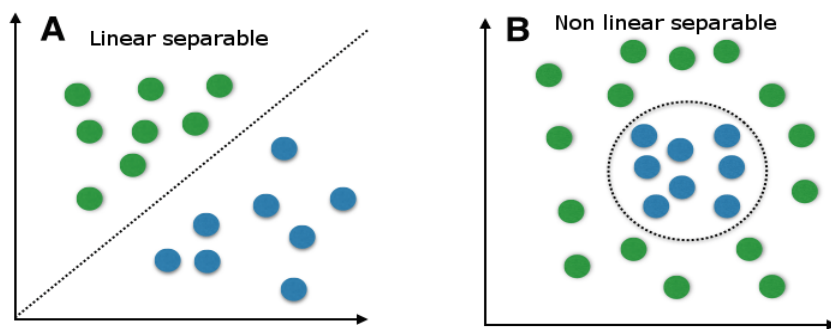


Abb. 2. Linear vs. non-linear separable SVM [L. Schultebraucks, 2017]

Auf der rechten Seite der Abbildung 2 (B) sehen wir die Lage einer Hyperebene bei nicht-linear separierbaren Daten. Da diese Daten schwerer zu trennen sind, wendet man den so genannten „Kerneltrick“ an. Dieser überführt den Vektorraum in eine höhere Dimension. In Abbildung 3 wird ein zweidimensionaler Vektorraum in einen dreidimensionalen Vektorraum abgebildet. Somit lassen sich dann die nicht-linear separierbaren Daten trennen. Anschließend wird der Vektorraum wieder in einen 2-dimensionalen Vektorraum zurück transferiert. [26]




Abb. 3. Kernel-Methode [J. Jordan, 2017]

Unüberwachtes Lernen.

Beim unüberwachten Lernen handelt es sich um das allgemeine Verstehen der vorliegenden Daten. Das System weiß nicht, was es erkennen soll. Das Ziel des unüberwachten Lernens ist es, Datengruppen in Cluster zu unterteilen. Dies dient vor allem dazu, bisher unbekannte Zusammenhänge und Strukturen zu erfassen. Jedoch ohne zu wissen, um welche Kategorien es sich handelt. Hierbei gibt es zwei Möglichkeiten: Segmentierung und Assoziationen. Bei der Segmentierung kommt es zu einer Partitionierung der Daten in Cluster ohne Vorgabe von Klasseneinteilungen, also das Gruppieren der Daten nach Gemeinsamkeiten. Im Bereich der Assoziationen werden ausschließlich Objekte betrachtet, die einen grundsätzlich vergleichbaren Informationsumfang haben. [21]

Zur Veranschaulichung der Unterschiede, eine Gegenüberstellung des überwachten und unüberwachten Lernens wird in Abbildung 4 dargestellt. Während man beim überwachten Lernen schon im Voraus weiß, dass es genau zwei Kategorien gibt (blauer Kreis oder rotes Kreuz), ergeben sich beim unüberwachten Lernen zwei Gruppen.

Beispielsweise die große Menge an Tweets in Twitter: Unüberwachtes Lernen ist, wenn man die Tweets anhand verschiedener Eigenschaften gruppieren will, sei es danach, wie „gut“ oder „perfekt“ ein Tweet geschrieben ist. Überwachtes Lernen dagegen ist, wenn man die Tweets klar nach „positiv“ oder „negativ“ kategorisiert: beispielsweise „beglückwünschend“ oder „sarkastisch“.

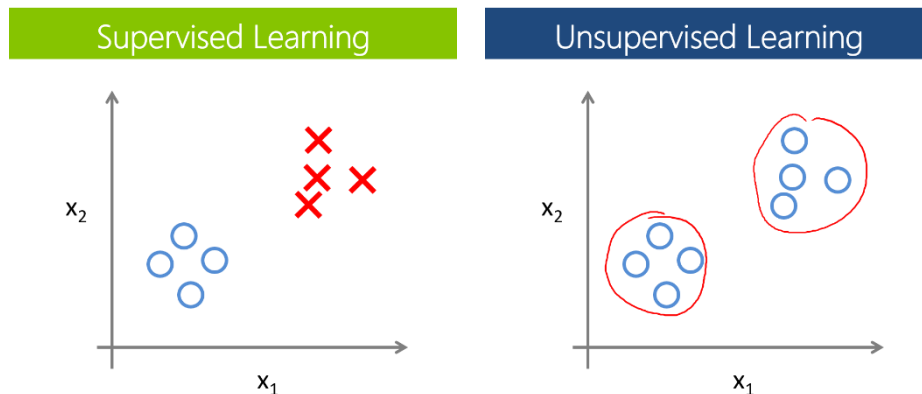


Abb. 4. Supervised vs. Unsupervised Learning [O. Klose, 2015]

4 Schlusswort

Die Sentiment-Analyse ist lediglich als Indikator zu verstehen, und je nach Wichtigkeit empfiehlt es sich, die Ergebnisse manuell zu verifizieren, denn wie alle automatisierten Prozesse ist sie fehleranfällig. Über die Verlässlichkeit hinaus sollte man erkennen, dass menschliche Aussagen nicht ohne weiteres in 3 Kategorien gepresst werden können: Nicht jedes Sentiment ist einfach negativ, positiv oder neutral.

Literaturverzeichnis

- [1] wikipedia.de, *Sentiment Detection*, https://de.wikipedia.org/wiki/Sentiment_Detection
- [2] B. Liu, *Sentiment Analysis and Opinion Mining*. Morgan & Claypool Publishers, May 2012. Zugriff: <https://www.cs.uic.edu/~liub/FBS/SentimentAnalysis-and-OpinionMining.pdf>
- [3] N. Stamm, *Klassifikation und Analyse von Emotionswörtern in Tweets für die Sentimentanalyse*. Universität Zürich, Institut für Computerlinguistik. 2014.
- [4] wikipedia.de, *Pragmatik*. [https://de.wikipedia.org/wiki/Pragmatik_\(Linguistik\)](https://de.wikipedia.org/wiki/Pragmatik_(Linguistik))
- [5] Meibauer, *Pragmatik*. Tübingen: Stauffenburg. 2001.
Zugriff: <http://fak1-alt.kgw.tu-berlin.de/call/linguistiktutorien/pragmatik/pragmatik%20k1.html>
- [6] vico-research.com, *Sentiment-Analyse*.
<https://www.vico-research.com/glossar/sentiment-analyse-htm/>
- [7] M. Wolfgruber, *Sentiment Analyse mit lokalen Grammatiken – Wissensbasierter Ansatz zur Extraktion von Sentiments in Hotelbewertungen*. 2015.
Zugriff: https://edoc.ub.uni-muenchen.de/18611/3/Wolfgruber_Marlene.pdf
- [8] C. Peng, M. Lakis, J. W. Pan, *Detecting Sarcasm in Text: An Obvious Solution to a Trivial Problem*. Stanford 2015.
Zugriff: http://cs229.stanford.edu/proj2015/044_report.pdf
- [9] social-media-abc.de, *Sentiment-Analyse*. Zugriff:
<https://social-media-abc.de/wiki/SentimentAnalyse>
- [10] A. Jurek, Y. Bi, M. Mulvenna, *Twitter Sentiment Analysis for Security-Related Information Gathering*. 2014. Zugriff: https://www.researchgate.net/publication/285624654_Twitter_Sentiment_Analysis_for_Security-Related_Information_Gathering
- [11] K. Bannister, *Die Sentimentanalyse: Was ist das? Warum wird sie eingesetzt?*. 2015.
Zugriff: <https://blog.hootsuite.com/de/die-sentimentanalyse-was-ist-das-warum-wird-sie-eingesetzt-2/>
- [12] Thomas K., *Sentiment-Analyse – Was ist das?*. Clickworker 2017.
Zugriff: <https://www.clickworker.de/2017/03/14/sentiment-analyse-was-ist-das/>
- [13] W. Medhat, A. Hassan, H. Korashy, *Sentiment analysis algorithmus and applications: A survey*. Ain Shams Engeneering Journal 2014.
Zugriff: <https://www.sciencedirect.com/science/article/pii/S2090447914000550>
- [14] M. Annett, G. Kondrak, *A Comparison of Sentiment Analysis Techniques: Polarizing Movie Blogs*. University of Alberta 2008.
Zugriff: https://www.researchgate.net/profile/Michelle_Annett/publication/221442023_A_Comparison_of_Sentiment_Analysis_Techniques_Polarizing_Movie_Blogs/links/5b2714eaa6fdcc69746ae801/A-Comparison-of-Sentiment-Analysis-Techniques-Polarizing-Movie-Blogs.pdf
- [15] WordNet®, *A Lexical Database for English*. Princeton University.
Zugriff: <https://wordnet.princeton.edu/>
- [16] GermaNet, *A German Wordnet*. Universität Tübingen.
Zugriff: <http://www.sfs.uni-tuebingen.de/GermaNet/>
- [17] SentiWS, *SentimentWortschatz*. Universität Leipzig.
Zugriff: <http://wortschatz.uni-leipzig.de/de/download>
- [18] N. M. Shelke, S. Deshpande, V. Thakre, *Survey of Techniques for Opinion Mining*. International Journal of Computer Applications 2012. Zugriff: <https://pdfs.semanticscholar.org/72f6/aa9289f136cc4ee78d8979b0a52be59f709e.pdf>

- [19] bigdata-insider.de, *Was ist Machine Learning?*
<https://www.bigdata-insider.de/was-ist-machine-learning-a-592092/>
- [20] J. Lehmann, M. Mittelbach, S. Schmeier, *Quantifizierung von Emotionswörtern in Texten*. Georg-August-Universität Göttingen 2017.
- [21] O. Klose, *Machine Learning (2) - Supervised versus Unsupervised Learning*. 2015.
 Zugriff: <http://oliviaklose.azurewebsites.net/machine-learning-2-supervised-versus-unsupervised-learning/>
- [22] T. Mini, *Sentiment Analyse*. Universität Passau 2016.
 Zugriff: https://www.academia.edu/30506244/Sentiment_Analyse
- [23] D. Jansen, *Sentiment Classification*. Universität Duisburg-Essen 2008.
 Zugriff: http://www.is.informatik.uni-duisburg.de/courses/sem_ss08/papers/p08_sentimentclass.pdf
- [24] B. Pang, L. Lee, S. Vaithyanathan, *Thumbs up? Sentiment Classification using Machine Learning Techniques*. 2002.
 Zugriff: <http://www.aclweb.org/anthology/W02-1011>
- [25] J. Fischer, *Support Vector Machines (SVM)*. Universität Ulm 2007.
 Zugriff: http://www.mathematik.uni-ulm.de/stochastik/lehre/ss07/seminar_sl/ausarbeitung_fischer.pdf
- [26] L. Schultebrasucks, *Einführung in Support Vector Machines*. 2017.
 Zugriff: <https://medium.com/@LSchultebrasucks/introduction-to-support-vector-machines-9f8161ae2fcb>

Abbildungsverzeichnis

- Abb. 1.** Sentiment-Klassifikationstechniken im Überblick [Medhat et al., 2014]5
 W. Medhat, A. Hassan, H. Korashy, *Sentiment analysis algorithmus and applications: A survey*. Ain Shams Engeneering Journal 2014. Seite 1095.
 Zugriff: <https://www.sciencedirect.com/science/article/pii/S2090447914000550>
- Abb. 2.** Linear vs. non-linear seperable SVM [L. Schultebrasucks, 2017] 11
 L. Schultebrasucks, *Einführung in Support Vector Machines*. 2017.
 Zugriff: <https://medium.com/@LSchultebrasucks/introduction-to-support-vector-machines-9f8161ae2fcb>
- Abb. 3.** Kernel-Methode [J. Jordan, 2017] 11
 J. Jordan, *Support-Vektor-Maschinen*. 2017.
 Zugriff: <https://www.jeremyjordan.me/support-vector-machines/>
- Abb. 4.** Supervised vs. Unsupervised Learning [O. Klose, 2015]12
 O. Klose, *Machine Learning (2) - Supervised versus Unsupervised Learning*. 2015.
 Zugriff: <http://oliviaklose.azurewebsites.net/machine-learning-2-supervised-versus-unsupervised-learning/>